

Localización del ligamento cruzado anterior en resonancias magnéticas de rodilla

Entregable 1: Comprensión del negocio y de los datos (CRISP-ML(Q), fase 1)

Christopher Zúñiga, C28730

Escuela de Ciencias de la Computación e Informática

Universidad de Costa Rica — CI-0148 Aprendizaje Automático

Resumen

Este documento corresponde al primer entregable del curso CI-0148 y desarrolla la fase 1 de CRISP-ML(Q): comprensión del negocio y de los datos. Se propone un proyecto de aprendizaje automático para **localizar el ligamento cruzado anterior (LCA)** dentro de volúmenes de resonancia magnética (RM) de rodilla, planteado como una tarea de detección de objetos (predicción de una caja delimitadora 3D) y no de clasificación de la severidad de la lesión. El proyecto reutiliza el conjunto de datos público KneeMRI [1], que ya incluye, para cada uno de sus 917 exámenes, una caja delimitadora manualmente extraída alrededor de la región del LCA. Este documento presenta el contexto clínico del problema, una revisión de trabajos relacionados en detección de LCA mediante aprendizaje profundo, el marco teórico necesario, la comprensión del negocio y de los datos disponibles, el estudio de factibilidad, la tabla de riesgos y aseguramiento de calidad, los objetivos del proyecto y el plan de trabajo para las fases restantes de CRISP-ML(Q).

Índice

1. Introducción	3
2. Revisión de literatura	4
3. Marco teórico	5
3.1. El ligamento cruzado anterior y su apariencia en RM	5
3.2. Caja delimitadora 3D y la métrica IoU	5
3.3. Detección de objetos frente a segmentación de instancias	5
4. Comprensión del negocio y de los datos	6
4.1. Objetivos de negocio y criterios de éxito	6
4.2. Inventario y descripción de los datos	7
4.3. Estudio de factibilidad	8
4.4. Riesgos, contingencias y aseguramiento de calidad (Q)	9
5. Objetivos	12
5.1. Objetivo general	12
5.2. Objetivos específicos	12
6. Plan	12
7. Conclusiones	14

1. Introducción

La ruptura del ligamento cruzado anterior (LCA) es una de las lesiones de rodilla más frecuentes en medicina deportiva y traumatología. Su diagnóstico definitivo depende de la interpretación de imágenes de resonancia magnética (RM) por parte de un radiólogo o traumatólogo especializado, quien debe primero *ubicar* el ligamento dentro de un volumen de cortes antes de poder evaluar su integridad. Este primer paso de localización, aunque anatómicamente rutinario para un especialista entrenado, consume tiempo de lectura y es un prerequisite para cualquier evaluación posterior, manual o automatizada, de la lesión.

La mayoría de los trabajos de aprendizaje automático aplicados a este dominio se han concentrado en la **clasificación** de la severidad de la lesión (sano, parcialmente lesionado, completamente roto) a partir del volumen completo o de una región ya recortada [2]. Este proyecto toma un enfoque distinto y, en cierto sentido, anterior en la cadena de procesamiento: en lugar de clasificar la severidad, se busca **localizar automáticamente el LCA** dentro del volumen de RM, es decir, predecir la caja delimitadora tridimensional que contiene al ligamento. Esta tarea de detección es la que efectivamente permite luego a un especialista, o a un modelo posterior, concentrar su atención en la región correcta del volumen, en vez de revisar los cortes completos.

El conjunto de datos utilizado es **KneeMRI** [1], un conjunto público de exámenes de RM de rodilla en plano sagital, recolectado y anonimizado en un entorno clínico, y disponible también en una versión redistribuida en Kaggle [3]. Un hallazgo central de este documento, verificado directamente sobre los metadatos del conjunto, es que **KneeMRI ya incluye una caja delimitadora (*bounding box*) 3D anotada manualmente para cada uno de sus 917 exámenes**, originalmente extraída por los autores del conjunto como paso de preprocesamiento previo a la clasificación de severidad. Este proyecto reutiliza esa anotación existente como la variable objetivo de una tarea de detección, sin necesidad de recolectar ni anotar un nuevo conjunto de datos.

Este documento corresponde al primer entregable del curso y cubre la **fase 1 de CRISP-ML(Q): comprensión del negocio y de los datos**. La estructura del resto del documento es la siguiente: la Sección 2 revisa trabajos relacionados en detección y localización de LCA mediante aprendizaje profundo; la Sección 3 desarrolla el marco teórico necesario (anatomía relevante, cajas delimitadoras, la métrica IoU, y la distinción entre detección y segmentación de instancias); la Sección 4 desarrolla la comprensión del negocio y de los datos, con sus cuatro subsecciones (objetivos y criterios de éxito, inventario de datos, estudio de factibilidad, y riesgos y aseguramiento de calidad); la Sección 5 formula el objetivo general y los objetivos específicos del proyecto; la Sección 6 presenta el plan de trabajo organizado según las seis fases de CRISP-ML(Q) y las fechas del curso; y la Sección 7 cierra con las conclusiones de esta primera fase.

2. Revisión de literatura

La detección automática del LCA en RM de rodilla ha sido abordada con distintas estrategias a lo largo de la última década, que van desde anotaciones manuales de caja delimitadora combinadas con redes convolucionales clásicas, hasta arquitecturas modernas de detección de objetos en tiempo real.

Uno de los primeros trabajos en usar explícitamente cajas delimitadoras para esta tarea es el de Liu et al. [2], quienes entrenaron una red convolucional para, en dos etapas, primero seleccionar los cortes coronales relevantes y luego determinar las coordenadas de la caja delimitadora alrededor de los ligamentos cruzados, antes de clasificar la presencia de ruptura; este trabajo estableció que la localización explícita del ligamento, previa a la clasificación, mejora la interpretabilidad y el desempeño del pipeline completo frente a clasificar el volumen sin recortar.

Trabajos más recientes han adoptado arquitecturas de la familia YOLO para la localización del LCA. Alic et al. [4] combinan una CNN personalizada con YOLOv9 para el diagnóstico de rupturas del LCA, reportando que la etapa de detección permite aislar consistentemente la región del ligamento antes de la clasificación. Yang et al. [5] proponen un marco basado en YOLOv10 mejorado específicamente para el reto de detectar objetos pequeños y de bajo contraste en RM de rodilla (una característica compartida con el LCA, cuya caja delimitadora ocupa típicamente una fracción del volumen total), demostrando mejoras estadísticamente significativas en mAP frente a YOLOv10 estándar, Faster R-CNN y detectores basados en transformadores.

Awan et al. [6] proponen MGACA-Net, una arquitectura con atención guiada multi-escala y agregación de contexto diseñada específicamente para localizar la región del LCA en RM, motivada por la dificultad de delimitar con precisión una estructura delgada y de bajo contraste rodeada de otros tejidos blandos. Wang et al. [7] presentan un pipeline "de un solo paso" que combina YOLOv5m para la localización con una ResNet-18 para la clasificación posterior, validado en múltiples centros clínicos, lo que respalda la viabilidad de separar la localización de la clasificación como dos tareas independientes y encadenables, tal como se plantea en este proyecto.

Finalmente, dado que el conjunto de datos utilizado en este proyecto solo provee cajas delimitadoras y no máscaras a nivel de píxel, resulta relevante mencionar el trabajo en segmentación débilmente supervisada a partir de cajas. Tian et al. [8] proponen BoxInst, un método que obtiene máscaras de segmentación de instancias a partir de únicamente anotaciones de caja, usando información de color de bajo nivel como señal auxiliar. De forma más reciente, el modelo Segment Anything (SAM) de Kirillov et al. [9] permite generar máscaras de segmentación a partir de una caja delimitadora como *prompt*, sin necesidad de reentrenamiento específico para el dominio. Estas técnicas no se emplean en el alcance de este entregable, pero se identifican como una vía natural de trabajo futuro para pasar de la detección de caja a una segmentación de instancias real del LCA, como se retoma en la Sección 5.

3. Marco teórico

3.1. El ligamento cruzado anterior y su apariencia en RM

El LCA es una estructura fibrosa intraarticular que conecta el fémur con la tibia y que es visible, como una banda oblicua de baja intensidad de señal que atraviesa un número reducido de cortes consecutivos dentro del volumen completo de la rodilla. Esta visibilidad acotada a pocos cortes (en el conjunto de datos utilizado, entre 2 y 6 de los 21 a 45 cortes totales del volumen, ver Sección 4.2) es la razón anatómica por la que la localización del LCA puede plantearse como un problema de detección de un objeto relativamente pequeño dentro de un volumen mucho mayor.

3.2. Caja delimitadora 3D y la métrica IoU

Una caja delimitadora (*bounding box*) 3D se define mediante un punto de origen (x, y, z) y sus dimensiones (ancho, alto, profundidad), y representa el menor prisma rectangular alineado a los ejes que contiene al objeto de interés. La métrica estándar para comparar una caja predicha $\hat{B}$ contra una caja de referencia B es la *Intersection over Union* (IoU), definida como

$$\text{IoU}(\hat{B}, B) = \frac{\text{vol}(\hat{B} \cap B)}{\text{vol}(\hat{B} \cup B)} \in [0, 1],$$

donde un valor de 1 indica coincidencia perfecta y 0 indica que las cajas no se traslapan. Esta métrica se usa tanto para evaluar el desempeño del modelo (Sección 4.1) como para definir una línea base cuantitativa a partir de los propios datos (Sección 4.1).

3.3. Detección de objetos frente a segmentación de instancias

Es necesario distinguir dos tareas de visión por computadora que suelen confundirse: la **detección de objetos** predice, para cada instancia, una caja delimitadora y una clase; la **segmentación de instancias** predice, además, una máscara a nivel de píxel (o vóxel) que delimita la forma exacta del objeto dentro de la caja. KneeMRI provee únicamente cajas delimitadoras anotadas manualmente por los autores del conjunto original como región de interés amplia alrededor del LCA [1], no máscaras a nivel de vóxel. Por esta razón, y como se justifica con más detalle en la Sección 4.3, este proyecto se plantea explícitamente como una tarea de **detección/localización**, y no de segmentación de instancias en sentido estricto, aunque en la Sección 5 se señala la generación de pseudo-máscaras por supervisión débil (Sección 2) como posible extensión futura del alcance.

4. Comprensión del negocio y de los datos

4.1. Objetivos de negocio y criterios de éxito

Objetivo de negocio. En el lenguaje del especialista clínico: *ubicar automáticamente el ligamento cruzado anterior dentro de un examen de resonancia magnética de rodilla, para que el radiólogo o traumatólogo dedique su tiempo de lectura a evaluar el estado del ligamento en la región correcta, en lugar de recorrer manualmente los cortes del volumen para encontrarlo.* Esto no reemplaza el juicio clínico sobre el estado del ligamento: acelera y estandariza el paso previo de ubicación anatómica.

Objetivo de aprendizaje automático. La tarea es de **detección de objetos (localización)**. La entrada es un volumen de RM de rodilla en formato de arreglo 3D (archivo .pck, con forma (cortes, 320, 320)). La salida es una única caja delimitadora 3D (x, y, z , alto, ancho, profundidad) que localiza al LCA dentro del volumen. La unidad de predicción es el examen completo (un volumen produce exactamente una caja), consistente con la forma en que el propio conjunto de datos anota un LCA por examen.

Métrica de negocio. No existe en este conjunto de datos un registro directo del tiempo que un radiólogo tarda en ubicar manualmente el LCA dentro del volumen, por lo que la métrica de negocio se declara como un **supuesto razonado, no un dato medido**: se asume que una localización automática con calidad suficiente (ver métrica de ML) reduce el tiempo de ubicación manual del especialista dentro del volumen, sin necesidad de recorrer cortes irrelevantes. Verificar esta reducción de tiempo con especialistas reales queda fuera del alcance de esta fase y se declara como trabajo de validación clínica posterior (fuera del alcance del curso).

Métrica de aprendizaje automático y línea base. La métrica principal es el IoU medio entre la caja predicha y la caja real, medido sobre el conjunto de prueba. Para fijar un umbral de éxito con base en datos reales y no en un número arbitrario, se construyó una línea base trivial: una sola caja "promedio", calculada como el punto medio de posición y tamaño (x, y, z , alto, ancho, profundidad) sobre los 917 exámenes del dataset, y comparada contra la caja real de cada examen como si fuera la única predicción posible. Esta caja fija obtiene un IoU medio de 0.391 (mediana 0.389): acierta con una superposición razonable (IoU 0.5) solo en 28.7 % de los casos, y con una superposición mínima (IoU 0.3) en 70.0 % de los casos. Se propone como umbral de éxito un IoU medio 0.5 en el conjunto de prueba (una mejora de aproximadamente 28 % sobre esta línea base), ya que superarlo exige que el modelo aprenda a ubicar y dimensionar la caja según cada volumen individual, en vez de repetir siempre la misma posición fija. Este umbral se revisará más adelante, una vez se cuente con resultados de modelos ya entrenados.

4.2. Inventario y descripción de los datos

Origen y proceso de generación. El conjunto KneeMRI fue recolectado en el Clinical Hospital Centre Rijeka, Croacia, entre 2006 y 2014, mediante un equipo Siemens Avanto 1.5T, usando una secuencia ponderada en densidad protónica con supresión de grasa en plano sagital (resolución en plano de 0.56 mm, espesor de corte de 3 mm, separación entre cortes de 3.6 mm) [1]. Cada examen fue evaluado por un especialista, quien asignó un diagnóstico de severidad del LCA y extrajo manualmente una región de interés rectangular más amplia que el ligamento mismo, como paso de preprocesamiento antes del análisis de textura del estudio original. El conjunto está disponible públicamente y redistribuido en Kaggle [3]; en este proyecto se accede a la versión de Kaggle mediante un script que usa la API de Kaggle.

Formato y variables. El conjunto consiste en un archivo `metadata.csv` de 917 registros y, por cada registro, un archivo `.pck` (arreglo de NumPy serializado) que contiene el volumen 3D en escala de grises de 12 bits. Las columnas de `metadata.csv` son: `examId`, `seriesNo` (identificadores del examen), `aclDiagnosis` (0 = sano, 1 = parcialmente lesionado, 2 = completamente roto), `kneeLR` (0 = izquierda, 1 = derecha), `roiX`, `roiY`, `roiZ`, `roiHeight`, `roiWidth`, `roiDepth` (la caja delimitadora 3D del LCA, en coordenadas de vóxel) y `volumeFilename` (nombre del archivo `.pck` correspondiente). La combinación (`examId`, `seriesNo`) identifica de forma única cada registro.

Cantidad y disponibilidad real. `metadata.csv` referencia 917 exámenes, pero al verificar la existencia de cada archivo `.pck` en disco (carpetas `vol01` a `vol08`) se confirmó que solo **736 de los 917** (80.3 %) están efectivamente presentes; los **181 archivos faltantes** corresponden todos a `examId` en el rango 919803–1028670. Esta limitación se documenta como hallazgo de calidad de datos (ver Sección 4.3 y Tabla 1) y se trabaja, para esta fase, con los 736 exámenes disponibles.

Estadística descriptiva. Sobre los 736 exámenes disponibles:

- **Distribución de `aclDiagnosis`:** 547 sanos (74.3 %), 144 parcialmente lesionados (19.6 %), 45 completamente rotos (6.1 %) — un desbalance de clases marcado, casi idéntico proporcionalmente al del conjunto completo de 917 (75.2 % / 18.8 % / 6.0 %), por lo que la pérdida de datos no parece introducir un sesgo adicional sobre esta variable.
- **Lateralidad (`kneeLR`):** distribución cercana a balanceada (448 izquierda / 469 derecha sobre el conjunto completo), sin sesgo lateral relevante.
- **Dimensiones de la caja del LCA:** `roiX` (media 114.5, DE 11.6), `roiY` (media 109.3, DE 15.6), `roiZ` (media 14.0, DE 1.4), `roiAlto` (media 91.8, DE 9.1), `roiAncho` (media 90.7, DE 10.1), `roiProfundidad` (media 3.36, DE 0.73, rango 2–6 cortes). La baja profundidad relativa de la caja frente a los 21–45 cortes del volumen confirma que el LCA ocupa una fracción muy pequeña del volumen total.
- **Forma de los volúmenes:** se identificaron 24 formas distintas de arreglo; la dimensión en plano es consistentemente 320×320 (con pocas excepciones), mientras que el número de cortes varía entre 21 y 45 (media 30.7, DE 2.3). Esta variabilidad en la dimensión de profundidad es relevante para el diseño del modelo (Sección 4.3).

- **Datos faltantes:** no hay valores nulos dentro de las columnas de `metadata.csv` para los registros presentes; la única forma de dato faltante identificada es la ausencia completa de 181 archivos `.pck`, descrita arriba.

Posibles sesgos de muestreo. El conjunto proviene de un único centro clínico, un único modelo de escáner y un único protocolo de adquisición (Siemens Avanto 1.5T, secuencia PD sagital), recolectado en un rango de años (2006–2014) durante el cual las prácticas de adquisición pudieron variar. Un modelo entrenado exclusivamente sobre este conjunto podría no generalizar a exámenes de otros centros, otros fabricantes de equipo, otras intensidades de campo (p. ej. 3T) u otros protocolos de secuencia. Este riesgo se retoma en la Sección 4.3 y en la Tabla 1.

4.3. Estudio de factibilidad

Disponibilidad y calidad de los datos. Los 736 exámenes disponibles ofrecen una cantidad razonable de datos para entrenar un detector de una sola clase (el LCA), aunque modesta frente a los conjuntos usados en detección de objetos en visión por computadora general. La calidad de la anotación es una preocupación central: el propio artículo original describe el ROI como una región *más amplia* que el ligamento, extraída manualmente como paso de preprocesamiento y no como una anotación de detección *tight* (ajustada) al objeto [1]. Esto significa que el "ground truth" de este proyecto es una aproximación razonable, pero no necesariamente la caja mínima que delimita el LCA, lo cual debe declararse explícitamente como limitación al reportar resultados. La aumentación de datos (rotaciones, traslaciones y variaciones de intensidad) es aplicable dado el tamaño del conjunto de datos; los datos sintéticos no se consideran necesarios en esta fase.

Aplicabilidad. La localización de una estructura anatómica de posición relativamente consistente (el LCA siempre se ubica en la región central-anterior de la articulación de la rodilla) es un problema donde el aprendizaje automático aporta valor frente a una heurística simple: la línea base trivial de una caja fija centrada en la posición promedio (Sección 4.1) ya alcanza un IoU medio de 0.391, lo que indica que existe una posición típica razonablemente informativa, pero insuficiente por sí sola (menos de un tercio de los casos supera $\text{IoU} \geq 0,5$). Esto sugiere que una solución no basada en aprendizaje (p. ej. una caja fija o una heurística de registro anatómico simple) sería insuficiente para variaciones individuales de anatomía y tamaño de rodilla, justificando el uso de un modelo entrenado.

Limitaciones legales y éticas. El conjunto de datos es una redistribución pública de un conjunto ya anonimizado y publicado en un artículo con revisión por pares [1]; no se recolectan datos nuevos de pacientes en este proyecto. No obstante, deben declararse como supuestos: (i) que el proceso de anonimización original fue adecuado (no se puede verificar directamente sobre los datos redistribuidos), y (ii) que el uso del conjunto para fines académicos es compatible con los términos de la redistribución en Kaggle. El riesgo de discriminación de algún grupo es bajo dado que la tarea (localizar una estructura anatómica) no depende de características demográficas, aunque el sesgo de un único centro/escáner (Sección 4.2)

podría afectar de forma desigual a poblaciones con características anatómicas o equipos de adquisición distintos a los del centro de origen.

Robustez y escalabilidad. La robustez ante variabilidad de forma de volumen (24 formas distintas, profundidad 21–45 cortes) debe resolverse en el diseño del modelo (p. ej. normalizando la entrada). La robustez ante datos fuera de distribución (otro escáner, otro campo magnético) no puede evaluarse con este conjunto por sí solo y se declara como limitación.

Explicabilidad. El dominio clínico exige que cualquier salida del modelo sea verificable por un especialista. Al tratarse de una tarea de detección, la salida (una caja delimitadora superpuesta al volumen) es, por construcción, más directamente interpretable que la salida de un clasificador de severidad: el especialista puede verificar visualmente, en segundos, si la caja predicha efectivamente contiene al LCA, sin necesidad de técnicas adicionales de explicabilidad como mapas de saliencia. Esto es una ventaja del enfoque de detección frente al de clasificación en cuanto a explicabilidad.

Disponibilidad de recursos. Se dispone de una computadora personal para desarrollo y entrenamiento; los volúmenes son de tamaño modesto (cientos de MB en total) y no se anticipan requerimientos de almacenamiento o red fuera de lo manejable en un entorno de curso. El recurso humano es un único estudiante, sin acceso directo a un experto clínico para validación cualitativa de resultados durante el curso, lo cual se declara como limitación y como riesgo (Tabla 1).

Reproducibilidad. Se versionará el código en control de versiones; los datos se obtienen de forma reproducible mediante un script de importación y la API de Kaggle (con la limitación conocida del 19.7% de archivos faltantes, Sección 4.2); las semillas aleatorias de los splits de entrenamiento/validación/prueba se fijarán y documentarán explícitamente, estratificando por `acLDiagnosis` para mantener proporciones de severidad comparables entre splits (aunque esta variable no sea el objetivo de predicción, ver Sección 5); el ambiente de ejecución (entorno virtual de Python) ya está versionado en el repositorio del proyecto.

Mantenibilidad y monitoreo. Un despliegue real de este modelo requeriría monitorear la degradación por cambio de dominio (nuevo escáner, nuevo protocolo de adquisición), lo cual podría detectarse comparando la distribución de intensidades o de tamaños de caja predicha contra la distribución de entrenamiento. La frecuencia de reentrenamiento y la infraestructura de monitoreo en producción exceden el alcance de este curso, pero se describen conceptualmente en el plan de la fase 6 (Sección 6).

4.4. Riesgos, contingencias y aseguramiento de calidad (Q)

La Tabla 1 resume los riesgos identificados para este proyecto, indicando la fase de CRISP-ML(Q) en la que aparecen, su impacto y probabilidad, el método de aseguramiento de calidad asociado, y la contingencia si el riesgo se materializa.

Cuadro 1: Riesgos, contingencias y aseguramiento de calidad (Q).

Riesgo	Fase CRISP- ML(Q)	Impacto Prob.		Método Q (ac- ción preventiva y criterio verifica- ble)	Contingencia
19.7 % de volúmenes .pck faltantes en disco	1. Compren- sión de datos	Medio	Alta (ya obser- vado)	Verificación au- tomatizada de existencia de archivo <code>metadata.csv</code> contra antes de cada entre- namiento; criterio: 0 registros usados sin archivo verificado	Trabajar con el subconjunto de 736 exámenes disponi- bles; documentar el porcentaje efectivo usado en cada re- porte de resultados
Caja de referencia ancha (no ajustada al LCA)	1. Compren- sión de datos	Medio	Alta (confir- mado en el artículo ori- ginal)	Inspección visual manual de una muestra aleatoria de cajas super- puestas a sus volúmenes; criterio: revisar ≥ 30 ejem- plos y documentar cualitativamente el ajuste	Reportar el umbral de éxito (Sec- ción 4.1) como una aproximación, con matiz explícito sobre la definición del ground truth
Objeto pequeño (LCA en 2–6 de 21–45 cortes) dificulta el aprendizaje	2. Prepara- ción de datos / 3. Modela- do	Alto	Media	Elegir arquitec- tura/función de pérdida adecuada para objetos pe- queños (p. ej. las evaluadas en [5]); criterio: IoU medio en validación $\geq$ línea base trivial (0.391) antes de considerar viable continuar	Si no se supera la línea base, reconsi- derar la represen- tación de la entra- da (recorte 2.5D por corte en vez de volu- men 3D completo)

Riesgo	Fase CRISP-ML(Q)	Impacto Prob.		Método Q (acción preventiva y criterio verificable)	Contingencia
Desbalance de <code>acldiagnosis</code> los splits si no se estratifica	1. Comprensión de datos 2. Preparación de datos	Bajo	Media	Generar splits estratificados por <code>acldiagnosis</code> con semilla fija; criterio: proporciones de clase por split dentro de ± 2 puntos porcentuales del conjunto completo	Volver a generar los splits si la verificación falla; documentar la semilla final usada
Fuga de información entre splits (mismo paciente/examen en train y test)	2. Preparación de datos	Alto	Baja	Verificar unicidad de <code>examId</code> entre splits antes de entrenar; criterio: intersección vacía de <code>examId</code> entre train/val/test	Regenerar los splits agrupando por <code>examId</code> si se detecta traslape
Sobreajuste por tamaño modesto del conjunto (736 exámenes)	3. Modelado	Medio	Media	Aumentación de datos y validación cruzada; criterio: brecha entre IoU de entrenamiento y validación < 0.1	Reducir la complejidad del modelo o incrementar regularización/aumentación si la brecha excede el criterio
Degradación del modelo ante datos de otro centro/escáner (sesgo de dominio único)	6. Monitoreo y mantenimiento	Alto	Media (a largo plazo)	Monitorear la distribución de tamaños de caja predicha en producción contra la distribución de entrenamiento; criterio: alerta si $> 10\%$ de predicciones caen fuera del rango intercuartílico histórico	Reentrenar o recalibrar con datos del nuevo dominio antes de continuar el despliegue

5. Objetivos

5.1. Objetivo general


Determinar la viabilidad de un modelo de aprendizaje automático capaz de localizar el ligamento cruzado anterior dentro de volúmenes de resonancia magnética de rodilla del conjunto KneeMRI, reutilizando las cajas delimitadoras ya anotadas en el conjunto de datos, con un desempeño de IoU medio superior a la línea base trivial calculada sobre los propios datos.

5.2. Objetivos específicos

1. Caracterizar estadísticamente el conjunto de datos KneeMRI (distribución de clases de `acldiagnosis`, lateralidad, dimensiones de caja delimitadora, forma de volumen, y disponibilidad real de archivos), documentando el proceso que genera los datos y no solo el archivo, como base de la fase 1 de CRISP-ML(Q).
2. Definir y calcular una línea base cuantitativa (caja promedio) contra la cual comparar cualquier modelo entrenado en fases posteriores, evitando así una comparación contra un umbral arbitrario.
3. Preparar splits de entrenamiento, validación y prueba estratificados por severidad de lesión (`acldiagnosis`) y agrupados por examen, documentando la semilla aleatoria usada, para poder replicarlo en la fase de preparación de datos.
4. Evaluar, en fases posteriores del curso, al menos un modelo de detección de objetos 3D (o adaptado a partir de una arquitectura 2D por corte) sobre el objetivo de localización del LCA, reportando IoU medio en el conjunto de prueba frente a la línea base definida.
5. Documentar como trabajo futuro, fuera del alcance de este curso, la extensión del enfoque de detección hacia segmentación de instancias real mediante generación de pseudo-máscaras por supervisión débil a partir de las cajas existentes (Sección 2), y hacia la clasificación de severidad (`acldiagnosis`) sobre la región ya localizada.

6. Plan

El plan se organiza según las seis fases de CRISP-ML(Q) y usa las fechas tentativas indicadas en la carta al estudiante del curso (definición del proyecto: martes 8 de setiembre; preprocesamiento de datos: martes 6 de octubre; implementación, evaluación e interpretación: martes 27 de octubre; presentación pública y entrega del artículo: viernes 27 de noviembre). Se respeta la distribución de esfuerzo esperada (fases de datos $\approx 50\%$, modelado y evaluación $\approx 25\%$, despliegue y gestión posterior $\approx 20\%$) y se reconoce explícitamente que el proceso es iterativo: los resultados de la fase de modelado pueden obligar a regresar a la preparación de datos (p. ej. si la representación de entrada no captura bien objetos pequeños), y los resultados de evaluación pueden obligar a redefinir el umbral de éxito de la Sección 4.1.



- **Fase 1 — Comprensión del negocio y de los datos (semanas 1–5, hasta el 8 de setiembre):** contenido de este entregable; ya completada para efectos de esta entrega, con posibilidad de ajuste si la fase 2 revela problemas de calidad de datos no anticipados.
- **Fase 2 — Preparación de datos (semanas 5–9, hasta el 6 de octubre):** verificación de disponibilidad real de archivos, generación de splits estratificados y agrupados por examen, normalización de volúmenes de profundidad variable, y decisión final sobre representación de entrada (volumen 3D completo frente a recorte 2.5D por corte), a partir de lo aprendido en la Sección 4.3.
- **Fase 3 — Modelado (semanas 9–12, hasta el 27 de octubre):** entrenamiento de al menos un modelo de detección; comparación contra la línea base trivial (IoU 0.391).
- **Fase 4 — Evaluación (semanas 11–12, hasta el 27 de octubre):** cálculo de IoU medio en el conjunto de prueba, análisis cualitativo de casos con IoU bajo, y contraste contra el umbral de éxito definido en la Sección 4.1.
- **Fase 5 — Despliegue (semanas 12–16, hasta el 27 de noviembre):** para efectos del curso, un prototipo in infraestructura de producción real; se documenta qué implicaría un despliegue real.
- **Fase 6 — Monitoreo y mantenimiento (más allá de la semana 16, descrita conceptualmente):** no se ejecuta dentro del curso; se describe el monitoreo de distribución de salidas propuesto en la Sección 4.3 como diseño conceptual de esta fase.

7. Conclusiones

Este entregable desarrolló la fase 1 de CRISP-ML(Q) para un proyecto de localización del ligamento cruzado anterior en resonancias magnéticas de rodilla. El hallazgo más relevante de esta fase es que el conjunto de datos KneeMRI, ya disponible en el proyecto, provee directamente la anotación necesaria para plantear esta tarea como detección de objetos (caja delimitadora 3D) sin necesidad de recolectar o anotar datos nuevos, lo cual reduce significativamente el riesgo de inviabilidad del proyecto por falta de datos. Se estableció además una línea base cuantitativa (IoU medio 0.391 con una caja fija promedio) que sirve como punto de comparación justificado para cualquier modelo entrenado en fases posteriores, y se definió un umbral de éxito (IoU medio ≥ 0.5) alcanzable pero no trivial.

Al mismo tiempo, esta fase identificó limitaciones concretas que condicionan el resto del proyecto: solo el 80.3% de los archivos referenciados están disponibles en disco, la anotación de caja es ancha y no ajustada estrictamente al ligamento, el objeto de interés es pequeño en relación con el volumen completo, y el conjunto proviene de un único centro y protocolo de adquisición. Ninguna de estas limitaciones se considera, por sí sola, motivo para descartar el proyecto, pero todas quedan documentadas como riesgos con su método de aseguramiento de calidad correspondiente (Tabla 1), de modo que puedan verificarse explícitamente durante las fases 2 a 4. Con esta base, el proyecto se considera viable para continuar hacia la fase de preparación de datos.

Referencias

- [1] I. Štajduhar, M. Mamula, D. Miletić, and G. Unéspegi, “Semi-automated detection of anterior cruciate ligament injury from MRI,” *Computer Methods and Programs in Biomedicine*, vol. 140, pp. 151–164, 2017.
- [2] F. Liu, B. Guan, Z. Zhou, A. Samsonov, H. Rosas, K. Lian, R. Sharma, A. Kanarek, J. Kim, A. Guermazi, and R. Kijowski, “Fully automated diagnosis of anterior cruciate ligament tears on knee MR images by using deep learning,” *Radiology: Artificial Intelligence*, vol. 1, no. 3, p. 180091, 2019.
- [3] S. Anwaar, “Knee MRI Dataset.” Kaggle, 2020. Derivado del conjunto de datos original de Štajduhar et al.
- [4] T. Alic, S. Zehir, M. Yalcinkaya, E. Deniz, H. E. Kiran, and O. Afacan, “Artificial intelligence-assisted accurate diagnosis of anterior cruciate ligament tears using customized CNN and YOLOv9,” *Frontiers in Radiology*, vol. 5, 2025.
- [5] H. Yang, W. Song, T. Jiang, C. Wang, L. Zhang, Z. Cai, Y. Sun, Q. Zhao, and Y. Sun, “An improved YOLOv10-based framework for knee MRI lesion detection with enhanced small object recognition and low contrast feature extraction,” *Frontiers in Artificial Intelligence*, vol. 8, 2026.
- [6] M. J. Awan, M. S. Mohd Rahim, N. Salim, H. Nobanee, A. A. Asif, and M. O. Attiq, “MGACA-Net: a novel deep learning based multi-scale guided attention and context aggregation for localization of knee anterior cruciate ligament tears region in MRI images,” *PeerJ Computer Science*, vol. 9, p. e1483, 2023.
- [7] M. Wang, C. Yu, M. Li, X. Zhang, K. Jiang, Z. Zhang, and X. Zhang, “One-stop detection of anterior cruciate ligament injuries on magnetic resonance imaging using deep learning with multicenter validation,” *Quantitative Imaging in Medicine and Surgery*, vol. 14, no. 5, pp. 3405–3416, 2024.
- [8] Z. Tian, C. Shen, X. Wang, and H. Chen, “BoxInst: High-performance instance segmentation with box annotations,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [9] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick, “Segment anything,” *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.